


ΠΡΟΧΩΡΗΜΕΝΑ ΘΕΜΑΤΑ ΒΑΣΕΩΝ ΔΕΔΟΜΕΝΩΝ ΕΞΑΜΗΝΙΑΙΑ ΕΡΓΑΣΙΑ


Ομάδα 23


Ονοματεπώνυμο: Καλαράς Γεώργιος **Α.Μ.:** 03118047 **Ονοματεπώνυμο:** Βαρής Αθανάσιος **Α.Μ.:** 03119606


Ζητούμενο 1:

Έγινε εγκατάσταση και διαμόρφωση του περιβάλλοντος με βάση και τις οδηγίες σε πόρους του okeanos. Οπότε βλέπουμε τα αναμενόμενα στοιχεία για τους 2 κόμβους στις κατάλληλες IP μέσα από έναν browser:









Spark 3.5.0 History Server

Event log directory: hdfs://okeanos-master:54310/spark.eventLog

Last updated: 2024-01-10 11:07:46

Client local time zone: Europe/Athens

No completed applications found!

Did you specify the correct logging directory? Please verify your setting of spark.history.fs.logDirectory listed above and whether you have the permissions to access it. It is also possible that your application did not run to completion or did not stop the SparkContext.

Show incomplete applications

Ζητούμενο 2:

Στο ερώτημα αυτό έπρεπε να δημιουργήσουμε ένα DataFrame από το βασικό σύνολο δεδομένων, διατηρώντας τα αρχικά ονόματα στηλών και προσαρμόζοντας κάποιους τύπους δεδομένων σύμφωνα με την εκφώνηση και τελικά να τυπώσουμε τον συνολικό αριθμό γραμμών του συνόλου δεδομένων και τον τύπο της κάθε στήλης. Παρακάτω φαίνεται ο κώδικας που γράψαμε για την υλοποίηση αυτού του ερωτήματος καθώς επίσης και το αποτέλεσμα που λάβαμε:

```
from pyspark.sql import SparkSession
from pyspark.sql.functions import col
from pyspark.sql.types import DateType, IntegerType, DoubleType
spark = SparkSession.builder.appName("LosAngelesCrime").getOrCreate()
main_dataset_path = "hdfs://okeanos-master:54310/user/user/ALLDATA/Crime_Data_from_2010_to_2019.csv"
main_dataset_path_sec = "hdfs://okeanos-master:54310/user/user/ALLDATA/Crime_Data_from_2020_to_Present.csv"
# Schema of Dataframe
main dataset schema = ("DR NO INT, Date Rptd STRING, DATE OCC STRING, TIME OCC STRING, AREA INT, "
                           "AREA NAME STRING, RPTDISTNO INT, PART12 INT, Crm Cd INT, CrmCd Desc STRING, Mocodes INT, "Vict_Age INT, Vict_Sex STRING, Vict_Descent STRING, Premis_Cd INT, "
# Creation of Dataframes (wiht the desired schemas) from CSVs
main_dataset = spark.read.csv(main_dataset_path, header=True, sep=',', schema=main_dataset_schema)
main dataset sec = spark.read.csv(main dataset path sec, header=True, sep=',', schema=main dataset schema)
main_dataset_df = main_dataset.union(main_dataset_sec)
main_dataset_df = main_dataset_df.withColumn("Date_Rptd", col("Date_Rptd").cast(DateType())))
main_dataset_df = main_dataset_df.withColumn("Vict_Age", col("Vict_Age").cast(IntegerType()))
main_dataset_df = main_dataset_df.withColumn("LAT", col("LAT").cast(DoubleType())))
main_dataset_df = main_dataset_df.withColumn("LON", col("LON").cast(DoubleType())))
# Show the total number of rows and data types of each column
print("Total number of rows: ", main_dataset_df.count())
```

```
root
|-- DR_NO: integer (nullable = true)
|-- Date_Rptd: date (nullable = true)
|-- DATE_OCC: date (nullable = true)
|-- TIME_OCC: string (nullable = true)
|-- AREA: integer (nullable = true)
|-- AREA.NAME: string (nullable = true)
|-- RPTDISTNO: integer (nullable = true)
|-- PART12: integer (nullable = true)
|-- Crm_Cd: integer (nullable = true)
|-- Crm_Cd_Desc: string (nullable = true)
|-- Mocodes: integer (nullable = true)
|-- Vict_Age: integer (nullable = true)
|-- Vict_Sex: string (nullable = true)
|-- Vict_Descent: string (nullable = true)
|-- Premis_Cd: integer (nullable = true)
|-- Premis_Desc: string (nullable = true)
|-- Weapon_Used_Cd: integer (nullable = true)
|-- Status_Desc: string (nullable = true)
|-- Status_Desc: string (nullable = true)
|-- Crm_Cd1: integer (nullable = true)
|-- Crm_Cd2: integer (nullable = true)
|-- Crm_Cd4: integer (nullable = true)
|-- Crss_Street: string (nullable = true)
|-- LOCATION: string (nullable = true)
|-- LOCATION: string (nullable = true)
|-- LOTION: double (nullable = true)
```

Ζητούμενο 3:

Στο ερώτημα αυτό υλοποιήσαμε το **Query 1** χρησιμοποιώντας DataFrame και SQL APIs. Και οι δύο υλοποιήσεις εκτελέστηκαν με 4 Spark executors. Παρακάτω βλέπουμε τους κώδικες των δυο υλοποιήσεων και τα αποτελέσματα που λάβαμε :

DataFrame:

```
from pyspark.sql.window import Window
from pyspark.sql.window import SparkSession
from pyspark.sql.functions import col,menth,year.count.to_timestamp.row_number.desc
from pyspark.sql.functions import col,menth,year.count.fo_timestamp.row_number.desc
from pyspark.sql.functions
fr
```

Εκτελέστηκε με την εξής εντολή:

user@okeanos-master:~/opt/scripts\$ spark-submit --num-executors 4 query1_Dataframe.py

Και τα αποτελέσματα που λάβαμε:

year	month	crime_total	#
2010	1	12930	1
2010	3	12873	2
2010	4	12301	3
2011	1	21321	1
2011	3	20987	2
2011	10	20866	3
2012	1	31423	1
2012	8	31041	2
2012	10	30921	3
2013	1	8691	1
2013	8	8008	2
2013	12	8001	3
2014	5	5296	1
2014	6	5248	2
2014	7	4830	3
2015	7 3 5	10200	1
2015	5	10018	2
2015	7	9785	3
2016	12	16670	1
2016	10	16616	2
2016	1	16430	3
2017	ī	27731	1
2017	3	27560	2
2017	7	27150	3
2018	1	6259	1
2018	8	5815	2
2018	7	5632	3
2019	7	19122	1
2019	8	18979	2
2019	3	18858	3
2020	8 3 1	5259	1
2020	2	5132	2
2020	5	4891	3
2021	7	28315	1
2021	10	28257	2
2021	8	27674	3
2022	7	31647	1
2022	8	31448	2
2022	10	30880	3
2023	8	25665	1
2023	7	25642	2
2023	1	25536	3
2023	1	23330	2

Από το web UI λάβαμε τις παρακάτω πληροφορίες, όπου παρατηρούμε ότι το query εκτελέστηκε σε 1 λεπτό και 3 δευτερόλεπτα :

Application application_1705318973565_0069

User:	user
Name:	Query1
Application Type:	SPARK
Application Tags:	
Application Priority:	0 (Higher Integer value indicates higher priority)
YarnApplicationState:	FINISHED
Queue:	default
FinalStatus Reported by AM:	SUCCEEDED
Started:	Tue Jan 16 09:46:21 +0200 2024
Launched:	Tue Jan 16 09:46:21 +0200 2024
Finished:	Tue Jan 16 09:47:25 +0200 2024
Elapsed:	1mins, 3sec
Tracking URL:	<u>History</u>
Log Aggregation Status:	DISABLED
Application Timeout (Remaining Time):	Unlimited
Diagnostics:	
Unmanaged Application:	false
Application Node Label expression:	<not set=""></not>
AM container Node Label expression:	<default partition=""></default>

SQL API:

```
Then pypears and import mystestation
from pypears and import perfections upper colloworth, to timestamp, row_number, desc
from pypears, and timestamp import Determine, foreigner, not perfect, not purpose, and import mystestamp integrating the perfect of your main dataset CTV file
main_dataset_path_sec "hids://demon-masteristil/user/aser/Alibert/Crise _Data_from_2010_to_2018.com"
main_dataset_path_sec "hids://demon-masteristil/user/aser/Alibert/Crise _Data_from_2010_to_2018.com"
main_dataset_path_sec "hids://demon-masteristil/user/aser/Alibert/Crise _Data_from_2010_to_2018.com"
main_dataset_path_sec "hids://demon-masteristil/user/aser/Alibert/Crise _Data_from_2010_to_2018.com"

# Creation of Dataframes (with the desired schemas) from CDVs
main_dataset = spart.read.com/main_dataset_path_sec, header*fine).select(to_timestamp(col(column_name), 'NEV/dd/yyyy hhimmiss a').alias('DATE_COC'))
main_dataset_datest_datest_union_ini_dataset_path_sec, header*fine).select(to_timestamp(col(column_name), 'NEV/dd/yyyy hhimmiss a').alias('DATE_COC'))
main_dataset_datest_datest_datest_union_ini_dataset_path_sec, header*fine).select(to_timestamp(col(column_name), 'NEV/dd/yyyy hhimmiss a').alias('DATE_COC'))
main_dataset_datest_datest_union_ini_dataset_path_sec, header*fine).select(to_timestamp(col(column_name), 'NEV/dd/yyyy hhimmiss a').alias('DATE_COC'))
main_dataset_datest_datest_union_ini_dataset_path_sec, header*fine).select(to_timestamp(col(column_name), 'NEV/dd/yyyy hhimmiss a').alias('DATE_COC'))
main_dataset_datest_union_ini_dataset_path_sec, header*fine).select(to_timestamp(col(column_name), 'NEV/dd/yyyy hhimmiss a').alias('DATE_COC'))
main_dataset_datest_dataset_datest_column_ini_dataset_path_sec, header*fine).select(to_timestamp(col(column_name), 'NEV/dd/yyyy hhimmiss a').alias('DATE_COC'))
main_dataset_dataset_dataset_dataset_path_sec_dataset_dataset_path_sec_dataset_dataset_path_sec_dataset_dataset_path_sec_dataset_dataset_dataset_dataset_datase
```

Εκτελέστηκε με την εξής εντολή:

```
user@okeanos-master:~/opt/scripts$ spark-submit --num-executors 4 query1_SQL.py |
```

Τα αποτελέσματα που λάβαμε ήταν ίδια με αυτά της υλοποίησης με το DataFrame (Δεν παρουσιάζονται ξανά για λόγους ευανάγνωστης αναφοράς).

Από το web UI λάβαμε τις παρακάτω πληροφορίες, όπου παρατηρούμε ότι το query εκτελέστηκε σε 1 λεπτό και 10 δευτερόλεπτα :

Application application_1705318973565_0074

User:	user
Name:	Query1
Application Type:	SPARK
Application Tags:	
Application Priority:	0 (Higher Integer value indicates higher priority)
YarnApplicationState:	FINISHED
Queue:	default
FinalStatus Reported by AM:	SUCCEEDED
Started:	Tue Jan 16 10:01:24 +0200 2024
Launched:	Tue Jan 16 10:01:25 +0200 2024
Finished:	Tue Jan 16 10:02:35 +0200 2024
Elapsed:	1mins, 10sec
Tracking URL:	<u>History</u>
Log Aggregation Status:	DISABLED
Application Timeout (Remaining Time):	Unlimited
Diagnostics:	
Unmanaged Application:	false
Application Node Label expression:	<not set=""></not>
AM container Node Label expression:	<default partition=""></default>

Από τους χρόνους που λάβαμε δεν μπορούμε σχετικά με το αν υπάρχει ουσιώδης διαφορά στην απόδοση των δύο ΑΡΙ. Θεωρούμε ότι η διαφορά των 7 δευτερολέπτων για την ολοκλήρωση των 2 εκτελέσεων είναι αμελητέα και δεν αρκεί για να χαρακτηρίσει αποδοτικότερο το ΑΡΙ DataFrame. Από την άλλη μία διαφορά που παρατηρήθηκε έγκειται στην ταχύτητα παραγωγής κώδικα. Ειδικότερα, ο εξοικειωμένος με την Python προγραμματιστής θα επωφεληθεί περισσότερο από το DataFrame API (Αντίστοιχα και ο εξοικειωμένος με την SQL προγραμματιστής με το SQL API).

Ζητούμενο 4:

Στο ερώτημα αυτό υλοποιήσαμε το **Query 2** χρησιμοποιώντας DataFrame και RDD APIs. Και οι δύο υλοποιήσεις εκτελέστηκαν με 4 Spark executors. Παρακάτω βλέπουμε τους κώδικες των δυο υλοποιήσεων και τα αποτελέσματα που λάβαμε:

DataFrame:

```
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, month, year, count, desc, when
from pyspark.sql.types import IntegerType
import time
spark = SparkSession.builder.appName("Query2_Dataframe").getOrCreate()
main_dataset_path = "hdfs://okeanos-master:54310/user/user/ALLDATA/Crime_Data_from_2010_to_2019.csv"
main_dataset_path_sec = "hdfs://okeanos-master:54310/user/user/ALLDATA/Crime_Data_from 2020_to Present.csv"
main_dataset = spark.read.csv(main_dataset_path, header=True).select("TIME OCC","Premis Desc")
main_dataset_sec = spark.read.csv(main_dataset_path_sec, header=True).select("TIME_OCC", "Premis_Desc")
main_dataset_df = main_dataset.union(main_dataset_sec)
def categorize_time(ts_column):
    return when((ts_column > '500') & (ts_column < '1159'), 'Morning')\
.when((ts_column > '1200') & (ts_column < '1659'), 'Afternoon')\
.when((ts_column > '1700') & (ts_column < '2059'), 'Night')\
         .otherwise('Late night')
start_time = time.time()
filtered_df = main_dataset_df.filter(main_dataset_df["Premis Desc"]=="STREET")
filtered_df = filtered_df.withColumn("TIME OCC",col("TIME OCC").cast(IntegerType()))
filtered df = filtered df.withColumn('Time Category', categorize time(col('TIME OCC')))
result df = (
    filtered_df.groupBy('Time_Category')
     .orderBy(desc('Occurrences'))
end time = time.time()
result df.show()
print ("Elapsed time only for the query calculation: ",end_time - start_time , "seconds")
```

Εκτελέστηκε με την εξής εντολή:

```
user@okeanos-master:~/opt/scripts$ spark-submit --num-executors 4 query2_Dataframe.py
```

Τα αποτελέσματα που λάβαμε είναι τα παρακάτω:

```
+-----+
|Time_Category|Occurrences|
+------+
| Late_night| 264531|
| Night| 153689|
| Afternoon| 122338|
| Morning| 112947|
+-----+
Elapsed time only for the query calculation: 0.8892695903778076 seconds
```

Αξίζει να σημειωθεί ότι ο χρόνος που φαίνεται κάτω από τα αποτελέσματα αφορά μόνο τον χρόνο που χρειάστηκε ο υπολογισμός του query και όχι ολόκληρη η εκτέλεση του προγράμματος.

Ο συνολικός χρόνος εκτέλεσης του προγράμματος φαίνεται από τις πληροφορίες που μας παρέχει το web UI:

Application application_1705318973565_0138

```
User: user
                              Name: Query2 Dataframe
                   Application Type: SPARK
                   Application Tags:
                 Application Priority: 0 (Higher Integer value indicates higher priority)
                YarnApplicationState: FINISHED
                             Queue: default
         FinalStatus Reported by AM: SUCCEEDED
                            Started: Wed Jan 17 10:36:33 +0200 2024
                          Launched: Wed Jan 17 10:36:34 +0200 2024
                           Finished: Wed Jan 17 10:37:20 +0200 2024
                           Elapsed: 46sec
                      Tracking URL: History
             Log Aggregation Status: DISABLED
Application Timeout (Remaining Time): Unlimited
                        Diagnostics:
             Unmanaged Application: false
   Application Node Label expression: <Not set>
 AM container Node Label expression: <DEFAULT_PARTITION>
```

RDD API:

```
from pyspark import SparkContext
from pyspark.sql import SparkSession
import time
spark = SparkSession.builder.appName("Query2 RDD").getOrCreate()
main_dataset_path = "hdfs://okeanos-master:54310/user/user/ALLDATA/Crime_Data_from_2010_to_2019.csv"
main_dataset_path_sec = "hdfs://okeanos-master:54310/user/user/ALLDATA/Crime_Data_from_2020_to_Present.csv"
# Read CSV files and select required columns
main_dataset_rdd = spark.read.csv(main_dataset_path, header=True).select("TIME OCC", "Fremis Desc").rdd
main_dataset_sec_rdd = spark.read.csv(main_dataset_path_sec, header=True).select("TIME OCC", "Premis Desc").rdd
main dataset rdd = main dataset rdd.union(main dataset sec rdd)
# Define function to categorize time
def categorize_time(ts_column):
        "Morning" if 500 < ts_column < 1159 else
        "Afternoon" if 1200 < ts_column < 1659 else
        "Night" if 1700 < ts_column < 2059 else
         "Late night"
#Start time
start_time = time.time()
filtered rdd = main dataset rdd.filter(lambda row: row["Premis Desc"] == "STREET")
filtered_rdd = filtered_rdd.map(lambda_row: (int(row["TIME_OCC"]), row["Premis_Desc"]))
filtered_rdd = filtered_rdd.map(lambda row: (row[0], row[1], categorize_time(row[0])))
         occurrences for each time category
result_rdd = filtered_rdd.map(lambda row: (row[2], 1)).reduceByKey(lambda x, y: x + y)
result_rdd = result_rdd.sortBy(lambda x: x[1], ascending=False)
end_time = time.time()
print("Result RDD:")
print(result rdd.collect())
print("Elapsed time only for the query calculation: ",end_time - start_time ,"seconds")
```

Εκτελέστηκε με την εξής εντολή:

```
user@okeanos-master:~/opt/scripts$ spark-submit --num-executors 4 query2_RDD.py
```

Τα αποτελέσματα που λάβαμε είναι τα παρακάτω:

```
[('Late_night', 264531), ('Night', 153689), ('Afternoon', 122338), ('Morning', 112947)]
Elapsed time only for the query calculation: 25.47447633743286 seconds
24/01/17 11:02:35 INFO SparkContext: Invoking stop() from shutdown hook
```

Όπως και στην Dataframe υλοποίηση ο χρόνος που αναγράφεται εδώ αφορά αποκλειστικά τον υπολογισμό του query και δεν αναφέρεται στο συνολικό χρόνο εκτέλεσης του προγράμματος ο οποίος φαίνεται παρακάτω:

Application application_1705318973565_0143

```
User:
                                     user
                              Name: Query2 RDD
                   Application Type: SPARK
                   Application Tags:
                 Application Priority: 0 (Higher Integer value indicates higher priority)
                YarnApplicationState: FINISHED
                             Queue: default
         FinalStatus Reported by AM: SUCCEEDED
                            Started: Wed Jan 17 10:57:46 +0200 2024
                          Launched: Wed Jan 17 10:57:47 +0200 2024
                           Finished: Wed Jan 17 10:59:10 +0200 2024
                           Elapsed: 1mins, 23sec
                      Tracking URL: History
             Log Aggregation Status: DISABLED
Application Timeout (Remaining Time): Unlimited
                       Diagnostics:
             Unmanaged Application: false
  Application Node Label expression: <Not set>
 AM container Node Label expression: <DEFAULT_PARTITION>
```

Παρατηρώντας τους παραπάνω χρόνους παρατηρούμε και πειραματικά ότι γνωρίζουμε ήδη θεωρητικά ότι δηλαδή η υλοποίηση με Dataframe είναι ταχύτερη/πιο αποδοτική σε σχέση με την υλοποίηση με RDD.

Ένας από τους λόγους που ισχύει αυτό είναι η υλοποίηση με τα Dataframe χρησιμοποιεί τον Catalyst Optimizer ο οποίος επανατοποθετεί τις εντολές σε καλύτερη σειρά, «κλαδεύει» αχρείαστες πράξεις/εντολές και γενικά χρησιμοποιεί διάφορες τεχνικές με στόχο την ταχύτερη εκτέλεση του προγράμματος/query (Λειτουργεί ως ενός είδους compiler).

Από την άλλη η υλοποίηση με RDD API δεν χρησιμοποιεί καθόλου τον Catalyst Optimizer με συνέπεια να μην έχει πρόσβαση στις βελτιστοποιήσεις που αυτός προσφέρει.

Ζητούμενο 5:

Εδώ, υλοποιήσαμε το **Query 3** με DataFrame API, για διαφορετικό πλήθος Spark executors (συγκεκριμένα για 2, 3 και 4). Ο κώδικας που χρησιμοποιήσαμε και τα αποτελέσματα που προέκυψαν φαίνονται παρακάτω.

Ο κώδικας, κοινός για όλες τις περιπτώσεις:

```
The Myspark, sql window import Window
from pyspark, sql window import Window
from pyspark, sql import sparkSession
spark = SparkSession.builder.appName("Query3_DataFrame").getOrCreate()

# The file paths of the csv files
main dataset path = "hdfs://okeanos-master:54310/user/user/ALIDATA/Crime_Data_from_2010_to_2019.csv"
median pousehold path = "hdfs://okeanos-master:54310/user/user/ALIDATA/Crime_Data_from_2010_to_2019.csv"
reverse_geocoding_path = "hdfs://okeanos-master:54310/user/user/ALIDATA/Crime_Data_from_2010_to_2019.csv"
main_dataset_df = spark.read.csv(median_household_path, header=True).select("Date_occ", "vict_Descent", "LAI", "LOH")
median_household_df = spark.read.csv(median_household_path, header=True).select("LAI", "LOH")
median_household_df = spark.read.csv(median_household_path, header=True).select("LAI", "LOH"), "zerode")

# Only data for 2015
main_dataset_df = main_dataset_df.filter(col("DATE_OCC").like("%2015%"))

# filtering for incorrect_victim_bescent
filtered_dataset_df = main_dataset_2015.filter((col("Vict_Descent").isMothull()) & (col("Vict_Descent") != "Unknown") & (col("Vict_Descent") != "o"))

# filtering for incorrect_victim_bescent
filtered_dataset_df = main_dataset_2015.filter(col("Vict_Descent").isMothull()) & (col("Vict_Descent") != "Unknown") & (col("Vict_Descent") != "o"))

# filtering for incorrect_victim_bescent
filtered_dataset_df = main_dataset_2015.filter(col("Vict_Descent").isMothull()) & (col("Vict_Descent") != "Unknown") & (col("Vict_Descent") != "o"))

# filtering for incorrect_victim_bescent
filtered_dataset_df = main_dataset_2015.filter(col("Vict_Descent").isMothull()) & (col("Vict_Descent") != "Unknown") & (col("Vict_Descent") != "o"))

# filtering for incorrect_victim_bescent
filtered_dataset_vith_income = dataset_with_income_grouphsy("zip_fode") ." "Loh", "Loh", "Loh", "Loh", "Loh", "Loh", "Loh", "Loh", "Loh", "Loh
```

```
# Dataset with only the 6 ZIP codes (the 3 highest and the 3 lowest ZIP codes by income)
combined_dataset = dataset_with_income.filter(col("ZIPcode").isin(all_income_zipcodes))
# number of victims per ethnic group for each ZIP code
result_df = combined_dataset.groupby("Vict Descent", "ZIPcode").agg(count("*").alias("Number of Victims"))
# results ordered by ZIP code
result_df = result_df.orderBy("ZIPcode", desc("Number of Victims"))
# showing the results
result_df.show(180)
```

Τα αποτελέσματα για τους 6 ζητούμενους ZIP codes που προέκυψαν, προφανώς τα ίδια και για τις τρεις υλοποιήσεις, είναι:

Number of Victims	Theode	ct Descent
3	90067	W
124	90094	w
36	90094	В
31	90094	H
1	90094	X.
16	90094	A
1	90094	F
636	90292	W
82	90292	H
75	90292	В
69	90292	Χĺ
27	90292	A
1	90292	F
11	91214	W
1	91214	H)
94	91326	W
21	91326	H
15	91326	A
4	91326	В
	91326	X.
985	91604	W
164	91604	H
67	91604	В
35	91604	A
	91604	X.
4	91604	F

```
Έτσι, τρέχοντας για 2 Spark executors την εντολή:

<u>user@okeanos-master:~/opt/scripts</u>$ spark-submit --num-executors 2 query3_Dataframe.py
```

Παίρνουμε ότι ο συνολικός χρόνος εκτέλεσης είναι 59 δευτερόλεπτα, όπως προκύπτει από το web UI:

Application application_1705318973565_0165

User: user Name: Query3_DataFrame Application Type: SPARK **Application Tags:** Application Priority: 0 (Higher Integer value indicates higher priority) YarnApplicationState: FINISHED Queue: default FinalStatus Reported by AM: SUCCEEDED Started: Wed Jan 17 13:19:30 +0200 2024 Launched: Wed Jan 17 13:19:31 +0200 2024 Finished: Wed Jan 17 13:20:30 +0200 2024 Elapsed: 59sec Tracking URL: History Log Aggregation Status: DISABLED Application Timeout (Remaining Time): Unlimited Diagnostics: Unmanaged Application: false Application Node Label expression: <Not set> AM container Node Label expression: <DEFAULT_PARTITION>

Για 3 Spark executors:

user@okeanos-master:~/opt/scripts\$ spark-submit --num-executors 3 query3_Dataframe.py

Ο συνολικός χρόνος εκτέλεσης είναι 1 λεπτό και 9 δευτερόλεπτα:

Application application_1705318973565_0166

User:	user
Name:	Query3_DataFrame
Application Type:	SPARK
Application Tags:	
Application Priority:	0 (Higher Integer value indicates higher priority)
YarnApplicationState:	FINISHED
Queue:	default
FinalStatus Reported by AM:	SUCCEEDED
Started:	Wed Jan 17 13:23:11 +0200 2024
Launched:	Wed Jan 17 13:23:11 +0200 2024
Finished:	Wed Jan 17 13:24:21 +0200 2024
Elapsed:	1mins, 9sec
Tracking URL:	History.
Log Aggregation Status:	DISABLED
Application Timeout (Remaining Time):	Unlimited
Diagnostics:	
Unmanaged Application:	false
Application Node Label expression:	<not set=""></not>
AM container Node Label expression:	<default partition=""></default>

Για 4 Spark executors:

user@okeanos-master:~/opt/scripts\$ spark-submit --num-executors 4 query3_Dataframe.py

Συνολικός χρόνος εκτέλεσης 1 λεπτό και 7 δευτερόλεπτα:

Application application_1705318973565_0167

User: user Name: Query3_DataFrame Application Type: SPARK **Application Tags:** Application Priority: 0 (Higher Integer value indicates higher priority) YarnApplicationState: FINISHED Queue: default FinalStatus Reported by AM: SUCCEEDED Started: Wed Jan 17 13:27:22 +0200 2024 Launched: Wed Jan 17 13:27:23 +0200 2024 Finished: Wed Jan 17 13:28:30 +0200 2024 Elapsed: 1mins, 7sec Tracking URL: History Log Aggregation Status: DISABLED Application Timeout (Remaining Time): Unlimited Diagnostics: Unmanaged Application: false Application Node Label expression: <Not set> AM container Node Label expression: <DEFAULT_PARTITION>

Παρατηρούμε ότι και στις 3 περιπτώσεις έχουμε παρόμοιους χρόνους εκτέλεσης. Συγκεκριμένα, πρόκειται για περίπου 1 λεπτό σε κάθε περίπτωση με μικρές διαφοροποιήσεις, όπου για 2 Spark executors έχουμε λίγο γρηγορότερη εκτέλεση.

Ζητούμενο 6:

Εδώ μας ζητείται να υλοποιήσουμε το query 4. Σε αυτό έχουμε 2 σκέλη.

Στο **πρώτο** υπολογίζουμε:

- a) Τον αριθμό εγκλημάτων με χρήση πυροβόλων όπλων και την μέση απόστασή τους (σε km) από το αστυνομικό τμήμα που ανάλαβε την υπόθεση ανά έτος
- b) Τον αριθμό εγκλημάτων με χρήση πυροβόλων όπλων και την μέση απόστασή τους (σε km) από το αστυνομικό τμήμα που ανάλαβε την υπόθεση ανά αστυνομικό τμήμα

Για να τα υλοποιήσουμε χρησιμοποιούμε τον παρακάτω κώδικα DataFrame API:

```
In pypark sol invert SparkSession
The pypark sol invertions import col, anoth, year, avg., count, to timestamp, row_number, desc, when
The pypark sol, invertions import college property to timestamp, row_number, desc, when
The pypark sol, itypes import to the stance property integer/pype, botaletype
The pypark sol, itypes import to the stance property integer/pype, botaletype
The pypark sol, itypes import to the stance property integer/pype, botaletype
The pypark sol, itype import to the stance property integer/pype, botaletype
The pypark sol, itype import to the stance property integer/pype, botaletype
The pypark sol, itype import to the stance property integer/pype, botaletype
The pypark sol, itype import to the stance property integer/pype, botaletype
The pypark sol, itype import to the stance property integer/pype, botaletype
The pypark sol, itype import to the stance property integer/pype, botaletype
The pypark sol, itype import to the stance property integer/pype, botaletype
The pypark sol, itype import to the stance property integer/pype, botaletype
The pypark sol, itype import to the stance property integer/pype, botaletype
The pypark sol, itype import to the stance property integer/pype, botaletype
The pypark sol, itype import to the stance property integer/pype, botaletype
The pypark sol, itype import to the stance property integer/pype, botaletype
The pypark sol, itype import to the stance property integer/pype, botaletype
The pypark sol, itype import to the stance property integer/pype, botaletype
The pypark sol, itype import to the stance property integer/pype, botaletype, itype integer/pype, itype integer/pype, itype int
```

```
### Casting coordinates to DoubleType
main dataset of = main dataset of f = main of f = police station of police station
```

Από αυτό παίρνουμε τα παρακάτω αποτελέσματα για τα ερωτήματα (α) και (β) αντίστοιχα:

+ Year	 average distance	++ number of incidents
+		++
2010	10932.579224107678	4763
2011	10931.000027341988	11754
2012	10931.113339205027	20506
2013	10923.11318178909	624
2014	10934.79255796961	2703
2015	10929.61745173897	3571
2016	10930.908916500157	6093
2017	10930.669408943533	14906
2018	10943.480320815295	120
2019	10930.42847476975	10451
2021	10930.884232171524	15347
2022	10930.744530612725	20691
2023	10929.906697142114	16721
+	 	 +

+	ļ	·+
DIVISION	average distance	number of incidents
+		
77TH STREET	10931.056821356187	27924
SOUTHEAST	10928.51684558062	17266
NEWTON	10936.193218969107	16497
OLYMPIC	10936.774883961521	9499
NORTHEAST	10946.106880950945	9413
WEST VALLEY	10917.214266226902	8846
MISSION	10932.168440005918	7819
NORTH HOLLYWOOD	10935.578025755782	7510
FOOTHILL	10939.393262873306	6858
PACIFIC	10914.42910191871	5959
DEVONSHIRE	10923.57819688867	5590
TOPANGA	10910.2069382779	5069
+	<u> </u>	+

Για την εκτέλεση αυτού, παίρνουμε και τον χρόνο ολικής εκτέλεσης από το web UI, που είναι 1 λεπτό και 15 δευτερόλεπτα, όπως φαίνεται:

Application application_1705568483929_0018

User:	user
Name:	Query4_First_Dataframe
Application Type:	SPARK
Application Tags:	
Application Priority:	0 (Higher Integer value indicates higher priority)
YarnApplicationState:	FINISHED
Queue:	<u>default</u>
FinalStatus Reported by AM:	SUCCEEDED
Started:	Thu Jan 18 12:37:43 +0200 2024
Launched:	Thu Jan 18 12:37:43 +0200 2024
Finished:	Thu Jan 18 12:38:58 +0200 2024
Elapsed:	1mins, 15sec
Tracking URL:	<u>History</u>
Log Aggregation Status:	DISABLED
Application Timeout (Remaining Time):	Unlimited
Diagnostics:	
Unmanaged Application:	false
Application Node Label expression:	<not set=""></not>
AM container Node Label expression:	<default_partition></default_partition>

(Όλοι οι κώδικες που φαίνονται παραπάνω υπάρχουν και στο παρακάτω GitHub repository)